

Análise Comparativa de Métodos para Detecção de Face Anti-Spoofing: LBP, Deep Learning e Histogramas de Cor

Fernando Daniel Marcelino
Marcos Alves de Aquino

Ícaro Travain Darwich da Rocha
Mateus Vespasiano de Castro

Dezembro de 2025

Resumo

Este trabalho apresenta uma análise comparativa de três métodos distintos para detecção de ataques de apresentação facial (*face anti-spoofing*), um problema crítico em sistemas de autenticação biométrica. Foram avaliados: (1) Local Binary Patterns (LBP) com classificador SVM, (2) Transfer Learning utilizando a arquitetura VGG16 pré-treinada no ImageNet, e (3) Histogramas de cor nos espaços HSV e YCbCr combinados com SVM. Os experimentos foram conduzidos no dataset NUAA, amplamente utilizado na literatura. ... [falar brevemente sobre os resultados e concluir ao final]

Palavras-chave: face anti-spoofing. NUAA. autenticação biométrica.

Introdução

A autenticação biométrica baseada em reconhecimento facial tem se tornado cada vez mais prevalente em sistemas de segurança, desde o desbloqueio de smartphones até controle de acesso em ambientes corporativos e governamentais. Entretanto, essa crescente adoção também ampliou a superfície de ataque para tentativas de falsificação, onde adversários tentam enganar sistemas de reconhecimento facial utilizando fotografias impressas, vídeos reproduzidos em telas ou máscaras 3D.

Os ataques de apresentação facial, também conhecidos como *face spoofing attacks*, representam uma ameaça significativa à integridade de sistemas biométricos (GALBALLY; MARCEL; FIERREZ, 2014). A detecção desses ataques, denominada *Presentation Attack Detection* (PAD) ou *face anti-spoofing*, tornou-se uma área de pesquisa ativa em visão computacional e segurança da informação.

Diversas abordagens têm sido propostas na literatura para detectar ataques de apresentação facial. Métodos baseados em textura, como *Local Binary Patterns* (LBP), exploram diferenças de micro-texturas entre faces reais e falsificadas (CHINGOVSKA; ANJOS; MARCEL, 2012). Abordagens baseadas em análise de cor (BOULKENAFET;

KOMULAINEN; HADID, 2015) aproveitam as distorções cromáticas introduzidas pelo processo de impressão ou exibição em telas. Mais recentemente, técnicas de *deep learning* baseadas em transferência de aprendizado e em estratégias de fusão/seleção de *deep features* têm demonstrado resultados promissores, aumentando robustez e acurácia em tarefas de reconhecimento visual (RASHID et al., 2020).

Este trabalho apresenta uma análise comparativa de três métodos distintos para detecção de face anti-spoofing: (1) Local Binary Patterns combinado com Support Vector Machine (LBP + SVM), representando a abordagem clássica baseada em textura; (2) Transfer Learning com VGG16, representando o paradigma de *deep learning*; e (3) Histogramas de cor nos espaços HSV e YCbCr combinados com SVM, explorando características cromáticas. Os experimentos foram conduzidos no dataset NUAA (AERONAUTICS; ASTRONAUTICS, 2010; TAN et al., 2010b), um *benchmark* amplamente utilizado para avaliação de métodos de anti-spoofing.

O objetivo principal é avaliar comparativamente o desempenho dessas três abordagens em termos de acurácia, *Half Total Error Rate* (HTER) e *Equal Error Rate* (EER), identificando vantagens e limitações de cada método. Os resultados obtidos contribuem para o entendimento de quais características são mais efetivas para a detecção de ataques de impressão fotográfica.

1 Metodologia

1.1 Datasets Utilizados

O estudo inicialmente foi pensado em comparar três métodos distintos de detecção de ataques de apresentação facial em apenas um *database*. Para tanto, foi necessário selecionar um conjunto de dados adequado para treinar e avaliar os modelos propostos. No entanto, o modelo estava inferindo muito bem sobre o conjunto pensado inicialmente, já que continha pouca variabilidade de indivíduos. Dessa forma, decidiu-se por utilizar dois conjuntos de dados distintos: NUAA e CASIA-FASD.

1.1.1 Dataset NUAA

O principal conjunto de dados utilizado neste estudo é o *NUAA Photograph Imposter Database*, fornecido pela *Nanjing University of Aeronautics and Astronautics* (NUAA). Este dataset é amplamente reconhecido na literatura para o desenvolvimento de sistemas de detecção de vivacidade facial (*face liveness detection*).

A base de dados contém um total de 12.614 imagens estáticas de 15 indivíduos diferentes, sendo 5.105 imagens de acesso real (genuínas) e 7.509 imagens de ataque (falsas/*spoofing*). As imagens foram capturadas em três sessões distintas, apresentando variações controladas de iluminação e ambiente. O foco exclusivo do dataset reside em ataques de *spoofing* de impressão 2D, utilizando fotografias impressas em papel fotográfico de diversos tamanhos, como $6,8 \times 10,2$ cm e papel A4.

1.1.2 Dataset CASIA-FASD

O segundo conjunto de dados utilizado é o *CASIA Face Anti-Spoofing Database* (CASIA-FASD), desenvolvido pelo *Chinese Academy of Sciences' Institute of Automation* (CASIA). Este dataset foi escolhido para avaliar a capacidade de generalização dos modelos treinados no NUAA, uma vez que o CASIA-FASD apresenta características distintas.

1.1.3 Organização de Dados

Na abordagem inicial, referenciada como `database_old`, o *dataset* era organizado sem restrições de identidade ou balanceamento de classes. Nesta versão, o sorteio das imagens para os conjuntos de treino e teste era puramente aleatório sobre o total de arquivos, o que permitia que imagens de um mesmo indivíduo estivessem presentes em ambos os conjuntos simultaneamente. No entanto, a versão atualizada do *pipeline* de dados implementa rigorosidade metodológica através de três pilares fundamentais:

- **Separação por IDs de Sujeitos (SubjectIndependent):** a separação do *dataset* baseada em IDs de sujeitos é essencial para garantir a integridade forense do sistema. Esta técnica evita o *Data Leakage* (vazamento de dados) ao assegurar que as fisionomias presentes no treinamento sejam inéditas no teste. Isso força o modelo a aprender padrões intrínsecos de textura e cor de vivacidade em vez de memorizar identidades específicas.
- **Equalização do Conjunto de Treino:** para mitigar o viés estatístico, aplicou-se a técnica de *Undersampling* no conjunto de treinamento. Ao igualar a quantidade de imagens reais e falsas, impede-se que o classificador SVM se torne tendencioso para a classe majoritária (ataques), garantindo que a fronteira de decisão seja estabelecida de forma justa.
- **Análise Multi-Seed (5 Sementes):** para validar a estabilidade e reprodutibilidade do modelo, o experimento foi executado sob cinco sementes de aleatoriedade distintas ($SEEDS = [42, 10, 23, 56, 89]$). Esta abordagem permite o cálculo de médias (μ) e desvios padrão (σ), fornecendo significância estatística e comprovando que os resultados não são fruto de um sorteio aleatório favorável.

1.2 Método 1: LBP e SVM

O Método 1 consiste em uma abordagem clássica baseada em textura para detecção de ataques de apresentação facial. Cada imagem facial é normalizada para o tamanho de 224×224 pixels e convertida para tons de cinza, conforme sugerido na literatura (KUSUMA et al., 2019). Em seguida, aplica-se o descritor Local Binary Patterns (LBP) na variante *uniforme*, utilizando $P = 16$ vizinhos e raio $R = 2$. O LBP uniformiza padrões de textura locais e gera um histograma de frequências que serve como vetor de características para a imagem.

Para evitar vazamento de dados, o conjunto de dados NUAA foi particionado de modo que não houvesse compartilhamento de sujeitos entre treino, validação e teste. Foi adotado um *hold-out* por sujeito, com aproximadamente 70 % dos sujeitos para treino, 20 % para validação e 10 % para teste. Adicionalmente, uma divisão “oficial-like” reproduz os tamanhos de treino e teste reportados na literatura (TAN et al., 2010a), garantindo 3.491 amostras reais e 5.761 falsas no treino e 1.614 reais e 1.748 falsas no teste. O processo de extração de características gera matrizes X_{train} , X_{val} e X_{test} , cada uma composta pelos histogramas LBP normalizados, acompanhados dos rótulos $y \in \{0, 1\}$ e metadados de sujeito/sessão.

Os vetores de características são padronizados via `StandardScaler` e utilizados como entrada para um classificador *Support Vector Machine* com kernel radial (RBF). Para lidar com o desbalanceamento entre classes, as ponderações de classe foram ajustadas de forma inversamente proporcional à frequência das classes. Os hiperparâmetros (C, γ) do

SVM foram selecionados com validação cruzada em grupos (**GroupKFold**) utilizando os sujeitos como grupos. A métrica de seleção adotada foi a área sob a curva ROC (AUC), dado que essa métrica reflete melhor o equilíbrio entre Falsa Aceitação (FAR) e Falsa Rejeição (FRR) do sistema. Por fim, o modelo escolhido foi treinado com todos os dados de treino+validação e avaliado no conjunto de teste.

1.3 Método 2: VGG16

O Método 2 emprega a arquitetura de rede neural convolucional VGG16, pré-treinada no conjunto de dados ImageNet, para a tarefa de detecção de ataques de apresentação facial. A escolha da VGG16 baseia-se em sua comprovada eficácia em tarefas de reconhecimento visual e sua capacidade de extrair características discriminativas de imagens.

1.4 Pré-processamento e Aumento de Dados

Para garantir a compatibilidade com a arquitetura da rede, todas as imagens foram redimensionadas para a dimensão espacial de 224×224 pixels. A normalização dos dados seguiu o padrão exigido pelo modelo pré-treinado (subtração da média RGB do conjunto ImageNet).

Para mitigar o risco de *overfitting* e aumentar a capacidade de generalização do modelo, foi implementada uma etapa de aumento de dados (*Data Augmentation*) em tempo de execução durante o treinamento. As transformações aplicadas incluem:

- Espelhamento horizontal aleatório.
- Rotação aleatória de até 10%.
- Zoom aleatório de até 10%.
- Ajustes aleatórios de contraste e brilho (fator de 0.2).

1.5 Arquitetura do Modelo

A estratégia de extração de características consistiu em remover as camadas densas originais (*top layers*) e congelar os pesos das camadas convolucionais (*backbone*), impedindo sua atualização durante a fase inicial de treinamento.

Sobre o extrator de características, foi acoplado um classificador personalizado composto por:

1. Uma camada de *Global Average Pooling*, que reduz a dimensionalidade dos mapas de características.
2. Uma camada de regularização *Dropout* com taxa de 0.5, para prevenir co-adaptação de neurônios.
3. Uma camada de saída com ativação *Softmax* para a classificação das N classes alvo.

1.6 Configuração Experimental e Treinamento

O modelo foi compilado utilizando o otimizador Adam com uma taxa de aprendizado inicial (α) de 0.001. A função de perda utilizada foi a Entropia Cruzada Categórica (*Categorical Cross-entropy*).

O treinamento foi configurado para um máximo de 20 épocas, com tamanho de lote (*batch size*) de 32. Foram empregados os seguintes callbacks para monitoramento e controle:

- **ModelCheckpoint:** Salvamento automático dos pesos do modelo que apresentaram o menor erro de validação.
- **EarlyStopping:** Interrupção prematura do treinamento caso não houvesse melhoria na perda de validação após 5 épocas consecutivas, restaurando-se os melhores pesos obtidos.

1.7 Método 3: Análise de Textura de Cor

O Método 3 foca na detecção de fraudes através da análise da distribuição de cores. A premissa fundamental é que ataques de *spoofing* (fotos impressas) introduzem distorções cromáticas previsíveis em comparação com capturas de rostos reais.

1.7.1 Processo de Extração e Treinamento

O *pipeline* de execução do Método 3 é dividido em três etapas principais, refletidas nos *scripts* desenvolvidos:

1. **Extração de Características (1_extract_cor.py):** As imagens são convertidas do espaço RGB para os espaços de cor **HSV** e **YCbCr**. O objetivo é isolar a informação de cor da luminância. São extraídos histogramas de 32 bins para os canais Hue (H), Saturation (S), Cb e Cr. Estes histogramas são concatenados para formar um vetor de características que resume a assinatura cromática da imagem.
2. **Classificação (2_svm.py):** Utiliza-se um classificador *Support Vector Machine* (SVM) com kernel *Radial Basis Function* (RBF). O modelo é treinado para encontrar o hiperplano que melhor separa os vetores de características das classes “real” e “fake”.
3. **Avaliação de Métricas (3_metrics.py):** O desempenho é avaliado através do cálculo da Acurácia, HTER (*Half Total Error Rate*) e EER (*Equal Error Rate*). São geradas matrizes de confusão, curvas ROC e histogramas de distribuição de scores para cada semente experimental.

2 Experimentos e Resultados

2.1 Método 1: LBP e SVM

A Tabela 1 resume as métricas obtidas pelo Método 1 no conjunto de teste NUAA. A matriz de confusão e a curva ROC correspondentes são exibidas na Figura 1. As métricas empregadas incluem acurácia, *False Acceptance Rate* (FAR), *False Rejection Rate* (FRR),

Half Total Error Rate (HTER) e *Equal Error Rate* (EER), definidas conforme as normas da biometria.

Tabela 1 – Métricas de desempenho do Método 1 (LBP + SVM) no conjunto de teste NUAA.

Métrica	Valor
Acurácia	0,9737
Precisão (classe real)	0,9813
Recall (classe real)	0,9727
FAR (%)	2,49
FRR (%)	2,73
HTER (%)	2,61
EER (% aprox.)	2,63
AUC (ROC)	0,9933

Observa-se que o método LBP+SVM alcançou acurácia de 97,37 % e AUC de 0,9933. As taxas de erro se mantêm próximas de 2,6 %, em especial o HTER e o EER. Comparativamente, a literatura reporta acurácias em torno de 92,5 % e HTER de 7,9 % para métodos baseados em LBP na NUAA. A redução das taxas de erro verificada nesta implementação pode ser atribuída à divisão de dados por sujeito, ao pré-processamento cuidadoso (normalização e recorte da face) e à otimização de hiperparâmetros com validação cruzada por grupo.




Figura 1 – À esquerda, matriz de confusão; à direita, curva ROC obtida para o Método 1 (LBP + SVM) no conjunto de teste NUAA. As imagens foram geradas pelos *scripts* de avaliação.

A matriz de confusão revela que 745 imagens falsas foram corretamente identificadas (verdadeiros negativos), enquanto 19 falsos positivos ocorreram. Do lado das imagens reais, 997 foram classificadas corretamente (verdadeiros positivos) e 28 foram classificadas como falsas (falsos negativos). A curva ROC mostra um desempenho discriminativo elevado, com AUC de 0,9933, corroborando a robustez do modelo frente às variações presentes no conjunto de teste.

2.1.1 Avaliação cruzada no CASIA-FASD

Uma questão relevante para sistemas de detecção de ataques de apresentação é a capacidade de generalização: um classificador treinado em uma base de dados deve manter bom desempenho quando exposto a amostras de outro domínio. Para investigar esse aspecto, avaliou-se o modelo LBP + SVM treinado no NUAA sobre um conjunto de teste proveniente da base CASIA-FASD. Diferentemente do NUAA, o CASIA-FASD contém ataques variados (fotografias impressas e fotografias com recortes para os olhos) e foi concebido como um complemento do NUAA, suprimindo a falta de diversidade de ataques. Os experimentos foram realizados utilizando as mesmas configurações de pré-processamento e extração de características.

As métricas obtidas nessa avaliação cruzada estão resumidas na Tabela 2. Para fins de comparação, incluem-se novamente as medidas de acurácia, precisão, recall, FAR, FRR, HTER, EER e AUC. A Figura 2 ilustra a matriz de confusão e a curva ROC correspondentes.

Tabela 2 – Métricas de desempenho do Método 1 (LBP + SVM) treinado no NUAA e testado no CASIA-FASD.

Métrica	Valor
Acurácia	0,7313
Precisão (classe real)	0,0000
Recall (classe real)	0,0000
FAR (%)	3,08
FRR (%)	100,0
HTER (%)	51,54
EER (% aprox.)	55,94
AUC (ROC)	0,4159




Figura 2 – À esquerda, matriz de confusão; à direita, curva ROC do Método 1 (LBP + SVM) treinado no NUAA e testado no CASIA-FASD.

Os resultados demonstram que o classificador treinado exclusivamente no NUAA não generaliza para o CASIA-FASD. A acurácia de 73,13% oculta um problema sério: todas as 591 imagens reais foram classificadas como falsas, resultando em recall zero e FRR de 100%. Como a classe “fake” representa cerca de 81% das amostras, a acurácia elevada decorre apenas do acerto nesses casos. A curva ROC apresenta AUC de 0,4159, inferior à

linha aleatória, indicando que as probabilidades atribuídas pelo modelo estão invertidas para o novo domínio. Esse fraco desempenho pode ser explicado pela divergência entre as características texturais das duas bases; o CASIA-FASD incorpora ataques com recortes e reproduções em vídeo cujos artefatos não estão presentes no NUAA. Estudos prévios apontam que métodos baseados em LBP apresentam níveis de certeza distintos dependendo do tipo de ataque e do banco de dados e que não existe uma característica única capaz de discriminar todos os ataques de forma consistente. Portanto, é necessário treinar com dados mais diversos ou adotar descritores mais robustos (por exemplo, histogramas de cor ou *deep features*) para obter generalização satisfatória.

2.1.2 Treinando no CASIA-FASD e testando no NUAA

Após os experimentos com a abordagem inicial, notou-se que o modelo gerado utilizando o *dataset* do NUAA não apresentou generalização em seu método. Por isso, pensou-se em treinar o modelo utilizando o mesmo método, mas com o *dataset* do CASIA-FASD, para então testá-lo no *dataset* do NUAA.

Após a realização do treinamento, notou-se que a melhor época apresentou as seguintes métricas: Acurácia de 90,28% e AUC-ROC de 0,9676. Ao testar o modelo treinado no *dataset* do NUAA, obteve-se uma acurácia de 85,58%, precisão de 97,64%, recall de 76,68%, FAR de 2,49%, FRR de 23,32% e HTER de 12,91%. A matriz de confusão e a curva ROC podem ser vistas na Figura 3.




Figura 3 – À esquerda, matriz de confusão; à direita, curva ROC do Método 1 (LBP + SVM) treinado no CASIA-FASD e testado no NUAA.

Os resultados indicam que o modelo treinado no CASIA-FASD generaliza melhor para o NUAA do que o contrário. A acurácia de 85,58% e a AUC de 0,9345 sugerem que as características texturais extraídas pelo LBP são mais representativas dos ataques presentes no NUAA quando o modelo é treinado com a diversidade do CASIA-FASD. No entanto, a taxa de rejeição de 23,32% ainda é elevada, indicando que o classificador tem dificuldade em reconhecer algumas faces reais do NUAA. Isso reforça a necessidade de conjuntos de dados mais abrangentes e técnicas de extração de características mais robustas para alcançar desempenho consistente em cenários do mundo real.

2.2 Método 2: VGG16

2.2.1 NUAA

O modelo VGG16, treinado e testado no dataset NUAA, demonstrou convergência ideal e desempenho superior na classificação de faces reais e ataques (*spoofing*). Conforme observado na Tabela 3, o modelo atingiu uma acurácia global de 99,94%.

Tabela 3 – Métricas de Desempenho no Dataset NUAA

Métrica	Valor Obtido
Acurácia (Accuracy)	99,94%
Área sob a Curva (AUC)	1,0000
Equal Error Rate (EER)	0,00%
Taxa de Falsa Aceitação (FAR)	0,13%
Taxa de Falsa Rejeição (FRR)	0,00%

A matriz de confusão 4 revelou que, de um total de 1.789 amostras de teste, o modelo cometeu apenas um erro, classificando incorretamente uma imagem *fake* como real. Isso resultou em uma Taxa de Falsa Rejeição (FRR) de 0,00% e uma Taxa de Falsa Aceitação (FAR) marginal de 0,13%, demonstrando uma separação quase perfeita das duas classes.




Figura 4 – Matriz de confusão método - NUAA

2.2.2 Avaliação CrossDataset (NUAA → CASIA-FASD)

Para avaliar a robustez do sistema em um cenário do mundo real, o modelo treinado exclusivamente no NUAA foi submetido ao dataset CASIA-FASD. Observou-se uma degradação significativa nas métricas de desempenho, evidenciando o fenômeno de mudança de domínio, esses resultados podem ser observados na figura 5.

A acurácia global caiu para 78,57%. Entretanto, a análise isolada da acurácia mascara o comportamento conservador do modelo. Ao analisar as taxas de erro, observou-se uma discrepância acentuada entre FAR e FRR:

- **FAR (1,93%):** O modelo manteve uma alta capacidade de segurança, bloqueando com sucesso quase 98% dos ataques de *spoofing*.
- **FRR (81,39%):** A taxa de rejeição de usuários legítimos foi excessivamente alta. De 591 acessos reais, o modelo rejeitou incorretamente 481 usuários.




Figura 5 – Matriz de confusão método 2 - CASIA-FASD

A curva ROC 6 apresentou uma AUC de 0,8005 e um *Equal Error Rate* (EER) de 29,50%. O ponto de operação do EER destaca que o limiar de decisão padrão (0,5) não é ideal para novos domínios, favorecendo excessivamente a classe *fake* em detrimento da classe *real*.




Figura 6 – Curva ROC - CASIA-FASD

Os resultados mostram que o modelo VGG16 possui capacidade suficiente para extrair características discriminativas, atingindo o excelente resultado no dataset em que foi treinado (NUAA). Porém, a queda de desempenho no teste *cross-dataset* revela que as

características aprendidas são fortemente dependentes do domínio de origem (iluminação, sensor da câmera, fundo e resolução do NUAA).

O alto índice de FRR (81,39%) no CASIA-FASD indica que o modelo aprendeu uma representação restrita do que constitui uma “face real” baseada apenas nas amostras do NUAA. Quando exposto às faces reais do CASIA-FASD, que possuem distribuições estatísticas diferentes, o classificador tendeu a rejeitá-las por não corresponderem ao padrão “real” memorizado.

Na prática, o sistema comporta-se como altamente seguro, mas pouco utilizável, pois embora bloqueie ataques com eficácia, impede o acesso da maioria dos usuários legítimos.

2.2.3 Avaliação CrossDataset (CASIA-FASD $\rightarrow$ NUAA)

Visando investigar se a direção da transferência de conhecimento impacta a capacidade de generalização do modelo, inverteu-se o protocolo experimental: o treinamento foi realizado exclusivamente no *dataset* CASIA-FASD, com a avaliação subsequente no *dataset* NUAA. Os resultados, apresentados na Figura 7, revelam uma degradação de desempenho ainda maior que o cenário anterior.

Das 1789 imagens presentes no conjunto de teste, apenas 1021 foram classificadas corretamente, resultando em uma acurácia de aproximadamente 57,07%. Este valor, próximo ao nível de chance para um problema binário, sugere que o modelo falhou em transpor os padrões aprendidos de um domínio para o outro. A análise das taxas de erro evidencia um comportamento crítico:

- **FAR (1,00%):** Similar ao teste anterior, o sistema apresentou uma taxa de aceitação falsa extremamente baixa, demonstrando rigor na detecção de ataques no novo domínio.
- **FRR (98,80%):** Observou-se um colapso na identificação de usuários legítimos. Praticamente toda a classe *real* do NUAA foi erroneamente classificada como *spoofing*, indicando um viés de decisão severamente deslocado para a classe negativa.




Figura 7 – Matriz de confusão método 2 - CASIA-FASD $\rightarrow$ NUAA

2.2.4 Treinando no CASIA-FASD e testando no NUAA

Com o mesmo motivo descrito na subseção 2.1.2, decidiu-se treinar o modelo VGG16 utilizando o *dataset* do CASIA-FASD, para então testá-lo no *dataset* do NUAA. Após o treinamento, o modelo apresentou uma acurácia de 42,93% ao ser testado no NUAA, com precisão de 60,00%, recall de 1,17%, FAR de 1,05%, FRR de 98,83% e HTER de 49,94%. A matriz de confusão e a curva ROC podem ser vistas na Figura 8.




Figura 8 – À esquerda, matriz de confusão; à direita, curva ROC do Método 2 (VGG16) treinado no CASIA-FASD e testado no NUAA.

Os resultados para o método 2, ao treinar no CASIA-FASD e testar no NUAA, indicam uma incapacidade significativa do modelo em generalizar entre os dois conjuntos de dados. A acurácia de 42,93% sugere que o classificador está performando ainda pior do que uma escolha aleatória, o que indica uma forte dependência das características específicas do conjunto de treinamento. O valor absurdamente alto do FRR mostra que o modelo não consegue reconhecer a maioria das faces reais do NUAA, rejeitando incorretamente 98,83% dos usuários legítimos.

Isso caracteriza um cenário impraticável para aplicações reais, onde a usabilidade é tão crucial quanto a segurança. A incapacidade de generalização pode ser atribuída às diferenças substanciais entre os dois *datasets*, incluindo variações na iluminação, qualidade da imagem, tipos de ataques e diversidade dos sujeitos. ===== A discrepância nos resultados corrobora a hipótese de que o modelo, embora eficaz no mesmo dataset, não extrai características universais da face humana ou da textura de materiais de ataque. Em vez disso, a rede VGG16 parece ter otimizado seus pesos para ruídos estatísticos específicos do CASIA-FASD, como padrões de iluminação de fundo, granulação do sensor e profundidade de cor.

Ao ser confrontado com o NUAA, que possui características ambientais e de captura distintas, o modelo interpretou a ausência dos artefatos específicos do treino como evidência de um ataque de *spoofing*. Conclui-se que a maior complexidade do CASIA-FASD não foi suficiente para ensinar ao modelo uma representação robusta o bastante para o *dataset* NUAA, reforçando o desafio imposto pela mudança de domínio em sistemas de biometria facial. »»»> d4a4c370ccd673b128db413ed2404251511da156

2.3 Método 3: Histogramas de Cor e SVM

A Tabela 4 consolida o desempenho obtido em diferentes cenários experimentais. Observa-se a queda de desempenho necessária para garantir a integridade forense (Database 1) e a variabilidade entre bases de dados distintas.

Tabela 4 – Comparação de métricas por abordagem e base de dados.

Cenário (Dataset)	Seed	Acurácia (%)	HTER (%)	EER (%)
Baseline (NUAA - Old)	-	99,13	0,98	0,66
Database 1 (NUAA)	10	77,42	19,72	2,73
Database 1 (NUAA)	23	76,30	20,72	3,22
Database 1 (NUAA)	42	77,25	19,87	2,88
Database 1 (NUAA)	56	76,52	20,52	3,27
Database 1 (NUAA)	89	76,30	20,72	2,75
Média Database 1	-	76,76	20,31	2,97
Database 2 (CASIA-FASD)	42	86,17	13,84	13,87

2.3.1 Avaliação de Generalização: Teste Cruzado entre Bases

Os resultados obtidos no experimento de teste cruzado (*cross-database testing*), utilizando a base CASIA-FASD para treinamento e o dataset NUAA para teste, revelaram uma degradação severa no desempenho do Método 3. Sob a semente 42, a acurácia do sistema despencou para 55,45%, com um erro de equilíbrio (*Equal Error Rate* - EER) de 46,86% e um HTER de 44,06%. Tais métricas situam o classificador em um patamar de desempenho marginalmente superior ao de uma escolha aleatória, contrastando drasticamente com o EER de 2,88% obtido no teste intra-base da NUAA.

Essa discrepância é atribuída ao fenômeno de *Domain Shift* (mudança de domínio), onde as características cromáticas aprendidas pelo SVM em um ambiente não se traduzem para o outro. A sensibilidade dos histogramas nos espaços de cor HSV e YCbCr faz com que variações na calibração dos sensores das câmeras, balanço de branco e propriedades de refletância do papel fotográfico entre as bases CASIA e NUAA sejam interpretadas erroneamente. Enquanto a base NUAA foca em ataques estáticos e planos, a complexidade da CASIA, que inclui fotos curvadas e recortes para simulação de piscada, gera uma assinatura de cor distinta que o modelo treinado não consegue generalizar para novos cenários de captura.

A Figura 9 ilustra a comparação entre a curva ROC apenas com a base CASIA-FASD e com a mudança de domínio.




Figura 9 – À esquerda, curva ROC para o CASIA-FASD; à direita, curva ROC do Método 3 treinado no CASIA-FASD e testado no NUAA.

Do ponto de vista da segurança da informação, estes resultados evidenciam que a análise pura de histogramas de cor, embora eficaz em ambientes controlados e específicos, carece de robustez para aplicações universais onde o hardware de captura não é padronizado. O alto índice de Falsa Rejeição (FRR) de 47,41% e Falsa Aceitação (FAR) de 40,71% demonstra que o sistema torna-se vulnerável e pouco prático sob mudança de domínio. Conclui-se, portanto, que para atingir níveis de segurança industriais, o Método 3 deve ser complementado por técnicas de normalização de cores mais agressivas ou integrado a abordagens híbridas que considerem características estruturais e de textura independentes da iluminação.

Conclusão

colocar qual metodo teve o melhor desempenho, um resumo de todos os testes

Para mitigar esse problema, sugere-se em trabalhos futuros a aplicação de técnicas de *Domain Adaptation* ou a calibração do limiar de decisão (*threshold calibration*) baseada no ponto de EER observado na curva ROC.

Comparative Analysis of Face Anti-Spoofing Detection Methods: LBP, Deep Learning and Color Histograms

Fernando Daniel Marcelino
Marcos Alves de Aquino

Ícaro Travain Darwich da Rocha
Mateus Vespasiano de Castro

Dezembro de 2025

Abstract

This work presents a comparative analysis of three distinct methods for face anti-spoofing detection, a critical problem in biometric authentication systems. The following methods were evaluated: (1) Local Binary Patterns (LBP) with SVM classifier, (2) Transfer Learning using VGG16 architecture pre-trained on ImageNet, and (3) Color histograms in HSV and YCbCr color spaces combined with SVM. The experiments were conducted on the NUAA dataset, widely used in the literature. Method 3 (Color Histograms + SVM) achieved the best results, reaching 99.13% accuracy, 0.98% HTER, and 0.66% EER. The results demonstrate that color-based features are highly discriminative for distinguishing real faces from photo print attacks, outperforming texture-based and deep learning approaches in this specific scenario.

Keywords: face anti-spoofing. presentation attack detection. machine learning. SVM. deep learning. biometrics.

Referências

AERONAUTICS, N. U. of; ASTRONAUTICS. *NUAA Photograph Imposter Database*. 2010. Dataset for Face Anti-Spoofing Research. Citado na página 2.

BOULKENAFET, Z.; KOMULAINEN, J.; HADID, A. face anti-spoofing based on color texture analysis. *CoRR*, abs/1511.06316, 2015. Disponível em: <<http://arxiv.org/abs/1511.06316>>. Citado na página 2.

CHINGOVSKA, I.; ANJOS, A.; MARCEL, S. On the effectiveness of local binary patterns in face anti-spoofing. In: *2012 BIOSIG - Proceedings of the International Conference of Biometrics Special Interest Group (BIOSIG)*. [S.l.: s.n.], 2012. p. 1–7. Citado na página 1.

GALBALLY, J.; MARCEL, S.; FIERREZ, J. Biometric antispoofing methods: A survey in face recognition. *IEEE Access*, v. 2, p. 1530–1552, 01 2014. Citado na página 1.

KUSUMA, I. B. et al. Image spoofing detection using local binary pattern and local binary pattern variance. *International Journal on Information and Communication Technology (IJoICT)*, v. 4, n. 2, p. 11–18, 2019. Disponível em: <<https://socjs.telkomuniversity.ac.id/ojs/index.php/ijoint/article/view/134>>. Citado na página 3.

RASHID, M. et al. A sustainable deep learning framework for object recognition using multi-layers deep features fusion and selection. *Sustainability*, v. 12, n. 12, 2020. ISSN 2071-1050. Disponível em: <<https://www.mdpi.com/2071-1050/12/12/5037>>. Citado na página 2.

TAN, X. et al. Face liveness detection from a single image with sparse low rank bilinear discriminative model. In: *Computer Vision – ECCV 2010*. [S.l.]: Springer, 2010. (Lecture Notes in Computer Science, v. 6316), p. 504–517. Citado na página 3.

TAN, X. et al. Face liveness detection from a single image with sparse low rank bilinear discriminative model. In: . [S.l.: s.n.], 2010. v. 6316, p. 504–517. ISBN 978-3-642-15566-6. Citado na página 2.